

研究总结

YOLO26 中 Mamba 组件归因与泛化边界研究

Matched controls and held-out evaluation reveal unstable Mamba attribution in YOLO26 traffic-object detection

项目	内容
研究定位	受控组件归因与独立评估
比较对象	C0 / C1-W / C1-C8
数据范围	UA-DETRAC-G2 与 VisDrone2019-DET

一句话结论 两个数据集上的开发集小幅收益均未在独立测试分区稳定复现；在严格匹配的分支中，Mamba 相对局部 Conv1d 混合器也没有呈现可复现的精度优势。

汇报结构

- 1. 任务如何从“YOLO 加模块”演进为受控归因研究
- 2. 三个模型与三个预定义归因效应
- 3. 两数据集、三随机种子和一次性独立评估协议
- 4. 主要精度与效率结果及其科学解释
- 5. 为什么这项工作具有发表价值，以及必须保留的结论边界

1. 任务背景与研究演进

本项目最初以 APM-YOLO11 为起点，希望通过轴池化 Mamba 分支改善密集车辆检测。30 轮筛选中，APM-YOLO11 的最佳 mAP50-95 相对 YOLO11n 提高约 0.0095，满足继续研究的筛选条件。

随着训练扩展到 100 epochs、多随机种子以及更严格的独立评估，性能变化表现出明显的种子依赖和分区依赖。如果继续只报告最有利的一次结果，很容易把完整复合分支的变化误写为 Mamba 本身的收益。

因此研究问题被重新定义：当一个检测器分支同时包含池化、序列化、LayerNorm、投影、残差门控和 Mamba 时，最终变化究竟来自完整分支，还是来自 Mamba mixer？这一转向构成最终论文的核心。

关键转折 研究没有因为原始增益不稳定而失败，而是从“追求正向性能结果”升级为“检验组件归因是否成立”。原始假设被限制或否定，本身就是可以发表的科学结果。

2. 科学问题与模型设计

2.1 三个严格匹配模型

变体	共享结构	唯一关键差异	实验角色
C0	原始 YOLO26n	不添加序列分支	参考基线
C1-W	共享门控宽度序列分支	packed bidirectional Mamba	完整 Mamba 分支
C1-C8	与 C1-W 相同的分支外壳	kernel-8 Conv1d	近参数匹配非 Mamba 对照


分支插入 YOLO26n 第一个自顶向下 P4 融合位置，即模型第 13 层。输入局部特征先沿高度求均值，形成宽度序列，经 LayerNorm、序列混合器和 64×64 投影后，再沿高度广播并通过零初始化标量门控残差加入原特征。

$$T = LN(Mean_H(L) \wedge T) \quad ; \quad L' = L + \gamma \cdot Broadcast_H(P(S(T)) \wedge T)$$


模型	检测器参数	新增分支参数	说明
C0	2,505,360	—	原始四类实现
C1-W	2,542,289	36,929	Mamba mixer 32,640 参数
C1-C8	2,542,481	37,121	仅比 C1-W 多 192 参数

C1-C8 与 C1-W 的总参数差异仅为 0.0076%，分支参数差异为 0.520%。因此 C1-C8 不是削弱版消融，而是能够隔离 mixer 身份的强匹配对照。

a Single insertion at top-down P4 fusion b Shared gated branch shell



c Mixer-only intervention and parameter match



d Paired attribution contrasts




图 1 共享分支、Mamba/Conv1d 替换关系与三项归因对比。

2.2 三个预定义归因效应

效应	计算方式	回答的问题
完整 Mamba 分支效应	$C1-W - C0$	加入整个 Mamba 分支后的总变化
匹配局部分支效应	$C1-C8 - C0$	共享分支加局部 mixer 后的变化
Mamba 替换效应	$C1-W - C1-C8$	在共享外壳内仅替换 mixer 的变化

归因规则 只有 $C1-W - C1-C8$ 可以解释为测试条件内的 Mamba substitution effect。 $C1-W - C0$ 不能单独证明 Mamba 有效，因为它同时包含整个分支的其他操作。

3. 数据与实验协议

数据集	分区	图像	实例	治理角色
UA-DETRAC-G2	训练	6,918	47,738	48 个序列；4 类车辆
UA-DETRAC-G2	开发验证	1,721	11,991	12 个序列；用于选 checkpoint
UA-DETRAC-G2	独立测试	2,231	—	40 个隔离序列；一次性开放

数据集	分区	图像	实例	治理角色
VisDrone	训练	6, 471	343, 204	10 个原生类别
VisDrone	开发验证	548	38, 759	官方 val; 用于选 checkpoint
VisDrone	test-dev	1, 610	75, 102	冻结后一次性评估

- 每个数据集执行 3 个模型 $\times$ 3 个随机种子，共 9 次正式训练；两个数据集合计 18 次 100-epoch 训练。
- 随机种子固定为 0、1、2；同一数据集和种子下共享兼容初始化、优化设置、增强方式和 evaluator。
- 每次训练按未改变的 Ultralytics fitness 规则选取最早达到最大值的 best checkpoint。
- 两个测试分区均在九个 checkpoint、评价代码、阈值和决策规则冻结后才开放。
- 测试结果不用于重新训练、调整阈值、挑选模型或新增结构。

3.1 工程与证据完整性

- 零门控初始化时，C1-W/C1-C8 输出与 C0 严格一致，同时门控梯度非零。
- FP32 与 AMP 下前向、反向、梯度有限性、Mamba 参数更新和检查点严格重载均通过。
- 真实 RTX 4090 CUDA smoke training、数据转换审计和完整验证集遍历均通过。
- 模型、权重、数据、日志、环境、checkpoint 和结果均使用 SHA256 绑定。
- 所有正向、负向和方向反转结果均保留，没有选择性汇报有利 seed。

4. 主要实验结果

论文以 mAP50-95 为主要指标。它在 IoU 0.50 至 0.95 的多个阈值上评价检测质量，比只看 mAP50 更严格，也更适合比较小幅组件效应。以下数值均为三个随机种子的均值 $\pm$ 样本标准差。

数据集与分区	C0	C1-W	C1-C8
UA-DETRAC-G2 development	0.632996 $\pm$ 0.019158	0.634052 $\pm$ 0.006917	0.642108 $\pm$ 0.012756
UA-DETRAC-G2 held-out	0.382510 $\pm$ 0.006178	0.384501 $\pm$ 0.011149	0.373510 $\pm$ 0.012454
VisDrone development	0.169658 $\pm$ 0.001293	0.170148 $\pm$ 0.001479	0.170554 $\pm$ 0.000610
VisDrone test-dev	0.140028 $\pm$ 0.000610	0.137899 $\pm$ 0.002551	0.138442 $\pm$ 0.000978
数据集与分区	C1-W - C0	C1-C8 - C0	C1-W - C1-C8


数据集与分区	C1-W - C0	C1-C8 - C0	C1-W - C1-C8
UA-DETRAC-G2 development	+0.001056	+0.009112	-0.008056
UA-DETRAC-G2 held-out	+0.001992	-0.008999	+0.010991
VisDrone development	+0.000489	+0.000896	-0.000407
VisDrone test-dev	-0.002129	-0.001585	-0.000544

4.1 最关键的跨分区现象

匹配局部分支 C1-C8 在两个开发分区上都高于 C0：UA-DETRAC-G2 为 +0.009112，VisDrone 为 +0.000896。但在两个独立测试分区上都转为负值：-0.008999 和 -0.001585。开发集上的分支优势没有跨分区复现。

Mamba 替换效应在四个分区依次为 -0.008056、+0.010991、-0.000407 和 -0.000544。UA-DETRAC-G2 上方向反转，VisDrone 上虽保持为负，但幅度低于 0.001。现有证据不支持稳定的 Mamba 特异性精度优势，也不支持局部 Conv1d 普遍更优。

核心科学结论 开发集上的模块收益不足以证明 named mixer 的真实贡献。只有在共享外壳的匹配对照和冻结的独立评估下，才能判断组件归因是否稳定。

图 2 两个数据集从 *development* 到 *held-out* 的模型排序与归因方向变化。

4.2 三随机种子原始 mAP50-95

分区	Seed	C0	C1-W	C1-C8
UA development	0	0.613409	0.626734	0.652517
UA development	1	0.651695	0.640483	0.627878
UA development	2	0.633884	0.634939	0.645929
UA held-out	0	0.385892	0.384279	0.359174
UA held-out	1	0.375379	0.395760	0.381658
UA held-out	2	0.386258	0.373465	0.379698
VisDrone development	0	0.169577	0.169216	0.170435
VisDrone development	1	0.168408	0.169374	0.170012
VisDrone development	2	0.170990	0.171853	0.171215

分区	Seed	C0	C1-W	C1-C8
VisDrone test-dev	0	0.140719	0.137219	0.137500
VisDrone test-dev	1	0.139566	0.135757	0.139451
VisDrone test-dev	2	0.139797	0.140721	0.138376

5. 效率结果

模型	FP16 native-forward	比较基准	相对变化
C0	6.399 ms	基线	—
C1-C8	6.832 ms	相对 C0	+6.777%
C1-W	7.903 ms	相对 C1-C8	+15.741% (C1-C8 快 13.600%)

效率测试使用 RTX 4090、batch 1、FP16、resident CUDA tensor 和同步 native-forward。每个模型在位置平衡矩阵中以独立进程重复四次，每次包含 200 个计时样本。

该结果说明 mixer 身份会改变计算成本：C1-C8 在参数量近似的前提下比 C1-W 快 13.600%。但这些数字不包含预处理、CPU-GPU 传输和 NMS，因此不能写成端到端部署延迟。




图 3 冻结 FP16 native-forward 协议下的批量 1 推理延迟。

6. 论文的真正结论

- 完整 Mamba 分支在四个分区中均未形成稳定、可复现的精度优势。
- 匹配局部分支在两个 development 分区略有优势，但在两个 held-out 分区均低于基线。
- Mamba substitution effect 的方向和幅度随数据分区变化，不能形成普遍结论。
- 开发集上的小幅提升不能自动写成组件贡献，更不能替代独立测试证据。
- 可信的组件归因应同时包含原始基线、完整目标分支、近参数匹配非目标 mixer，以及冻结的独立评估。

7. 为什么这项工作具有发表价值

1. **研究问题真实**：许多检测论文把复合模块的全部收益归给其中的 Mamba，但普通 baseline 对比不能证明这种归因。
2. **对照设计有解释力**：C1-W 与 C1-C8 只改变 mixer，分支外壳、参数量、初始化、训练和评估协议高度匹配。
3. **负结果形成新知识**：论文没有简单宣布 Mamba 无效，而是证明开发集收益不能稳定支持 Mamba 特异性解释。
4. **证据链完整**：两个数据集、三配对种子、18 次正式训练、18 个冻结 checkpoint 的独立评估和完整效率测试构成闭环。
5. **两次独立复现增强可信度**：C1-C8 的 development 优势在 UA-DETRAC-G2 和 VisDrone 的 held-out 分区均转为负值。
6. **结果可复核**：模型、权重、数据、环境、checkpoint、结果和图表源数据均由 SHA256、manifest 和 QA 记录绑定。
7. **期刊定位匹配**：CVIU 不只关注排行榜，也重视能推进计算机视觉理解的方法学与实证结果。本研究解释了如何区分 branch effect 与 mixer effect。

8. 必须保留的边界与风险

限制	正确解释
三随机种子	只能做描述性配对分析，不能声称统计显著。
一个尺度与插入点	不能推广到所有 YOLO26 尺度、所有 neck 位置或所有检测器。
一个 Mamba 配置	不能声称 Mamba 在目标检测中普遍无效。
一个 Conv1d 对照	不能声称 Conv1d 是普遍最佳 mixer。
两个交通数据集	结论边界仍主要位于交通目标检测。
单 GPU 软件栈	延迟结论仅适用于冻结的 RTX 4090 eager-PyTorch 测量范围。
VisDrone 绝对精度 modest	论文不做排行榜比较；主要估计的是匹配条件下的组件差值。

疑问解析：

Q1：没有明显提升，论文是不是失败了？

不是。原始性能假设没有得到稳定支持，但研究通过更强对照发现了开发集归因不稳定这一方法学结果。负结果只有在设计严谨、证据完整且解释有普遍启示时才有发表价值，本项目满足这三个条件。

Q2：为什么 VisDrone 的绝对 mAP50-95 只有约 0.17？

VisDrone 包含密集小目标、十个类别和无人机视角，任务更难。本研究没有对 VisDrone 做排行榜式调参，三个模型共享同一冻结协议；论文关心的是匹配差值，而不是宣布新 SOTA。

Q3：为什么 UA-DETRAC held-out 比 development 低很多？

后续审计未发现标签转换错误，但测试分区实例密度约为 development 的 1.72 倍，类别组成也不同。这些差异可解释为分区变化的背景证据，但不能声称它们因果导致了下降。

Q4：能否直接说 Mamba 不如 Conv1d？

不能。VisDrone 上 Mamba substitution 接近零；UA-DETRAC held-out 上方向还发生反转。正确说法是：未观察到跨分区可复现的 Mamba 特异性优势。

Q5：为什么不继续增加模块或重新挑测试集？

因为测试集已经一次性开放，继续根据测试结果改结构会破坏独立证据。若扩展研究，应建立新的预注册实验或使用新的数据集，而不能反复利用现有 held-out 反馈。

10. 当前论文与材料状态

材料	状态	说明
匿名论文正文	完成	CVIU_ANONYMOUS_MANUSCRIPT_V4. docx
正文结构	完成	Abstract + 6 个正文部分 + 17 篇参考文献
主图	完成	架构图、跨分区归因图、延迟图
补充图表	完成	训练轨迹、类别级 held-out 对比、S1-S4 表
证据审计	通过	正文、图表、数据源、哈希和匿名性均有 QA 记录
新增 GPU 实验	不需要	现有限定主张已形成证据闭环
投稿行政材料	待补	作者顺序、单位、基金、CRediT、利益冲突、数据/代码声明、cover letter
最终提交前	待执行	对 V4 进行最终 PDF 渲染、匿名元数据和投稿网站要求复核

附录 A. 论文核心指标速查

以下为论文主表使用的最终冻结数值。模型值为三随机种子均值 $\pm$ 样本标准差；效应值为配对均值。

数据集与分区	C0	C1-W	C1-C8
UA-DETRAC-G2 development	0.632996 $\pm$ 0.019158	0.634052 $\pm$ 0.006917	0.642108 $\pm$ 0.012756
UA-DETRAC-G2 held-out	0.382510 $\pm$ 0.006178	0.384501 $\pm$ 0.011149	0.373510 $\pm$ 0.012454
VisDrone development	0.169658 $\pm$ 0.001293	0.170148 $\pm$ 0.001479	0.170554 $\pm$ 0.000610
VisDrone test-dev	0.140028 $\pm$ 0.000610	0.137899 $\pm$ 0.002551	0.138442 $\pm$ 0.000978

数据集与分区	完整 Mamba 分支	匹配局部分支	Mamba 替换
UA-DETRAC-G2 development	+0.001056	+0.009112	-0.008056
UA-DETRAC-G2 held-out	+0.001992	-0.008999	+0.010991
VisDrone development	+0.000489	+0.000896	-0.000407
VisDrone test-dev	-0.002129	-0.001585	-0.000544

模型	参数/延迟	解释
C1-W	2,542,289 参数; 7.903 ms	完整 Mamba 分支
C1-C8	2,542,481 参数; 6.828 - 6.832 ms	比 C1-W 快 13.600%
C0	2,505,360 参数; 6.399 ms	原始基线

最终可发表结论 在两个交通目标检测数据集、三配对种子和一次性独立评估下，开发集上的 gated sequence branch 小幅收益没有稳定泛化；Mamba 相对近参数匹配局部 mixer 也未呈现可复现的特异性优势。因此，matched non-Mamba controls 与 held-out evaluation 是可信组件归因所必需的。